

Министерство образования Республики Беларусь

Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет информационных технологий и управления
Кафедра интеллектуальных информационных технологий

К защите допустить:

Заведующий кафедрой ИИТ

_____ Д. В. Шункевич

ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
к курсовому проекту
по дисциплине «Математические основы интеллектуальных систем»
на тему:

**БАЗА ЗНАНИЙ СИСТЕМЫ АВТОМИЗАЦИИ
ПРОВЕРКИ СТУДЕНЧЕСКИХ РАБОТ**

БГУИР КП4 6-05-0611-03 042 ПЗ

Студент гр. 421701
Проверяющий

Е. К. Федосов
Н. А. Гуменный

Минск 2026

Министерство образования Республики Беларусь
Учреждение образования
БЕЛОРУССКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
ИНФОРМАТИКИ И РАДИОЭЛЕКТРОНИКИ

Факультет
Специальность

ИТиУ
6-05-0611-03

Кафедра

ИИТ

УТВЕРЖДАЮ

_____ Зав. кафедрой
«____» _____ 2026 г.

ЗАДАНИЕ

по курсовому проекту студента

Федосов Егор Константинович

(фамилия, имя, отчество)

1. Тема работы: База знаний системы автоматизации проверки студенческих работ

2. Срок сдачи студентом законченной работы: 11.05.2026

3. Исходные данные к проекту: _____

4. Содержание пояснительной записки (перечень подлежащих разработке вопросов):

Введение

1 Анализ подходов к разработке системы автоматизации проверки студенческих работ .

2 Проектирование системы автоматизации проверки студенческих работ .

3 Разработка системы автоматизации проверки студенческих работ .

Заключение

5. Перечень графического материала (с точным указанием обязательных чертежей):
Компьютерная презентация курсового проекта _____

КАЛЕНДАРНЫЙ ПЛАН

п/п	Наименование этапов курсовой работы	Объем этапа, %	Срок выполнения этапов	Примечание
1	Подбор и изучение литературы	10	9.02 – 20.02	
2	Изучение проблемной области, средств проектирования и разработки	10	21.02 – 27.03	
3	Определение требований к базе знаний системы	10	28.02 – 06.03	
4	Проектирование модели базы знаний системы	25	07.03 – 13.04	
5	Реализация базы знаний системы	30	14.04 – 08.05	
6	Оформление пояснительной записки	10	01.05 – 11.05	
7	Оформление графической части проекта	5	06.05 – 11.05	

Дата выдачи задания: 20.02.2026 г. Проверяющий _____ Е. К. Федосов

Задание принял к исполнению _____ Н. А. Гуменный

СОДЕРЖАНИЕ

Перечень условных обозначений	4
Введение	5
1 Анализ предметной области и требований к базе знаний	6
1.1 Характеристика предметной области	6
1.2 Типы задач и сценарии использования	6
1.3 Анализ существующих решений и баз знаний	8
1.4 Характеристика аналогичных решений	9
1.5 Анализ требований к базе знаний	10
1.6 Требования к видам знаний и формализму	11
1.7 Вывод по разделу анализа	12
2 Проектирование базы знаний интеллектуальной системы	13
2.1 Общая архитектура интеллектуальной системы и место моду- ля базы знаний на основе Neo4j	13
2.2 Выбор графового формализма и логической основы	14
2.3 Концептуальная графовая модель данных	16
2.4 Логическая и физическая структура модуля базы знаний	18
2.5 Моделирование видов знаний и запросов в Neo4j	20
2.6 Обеспечение согласованности, расширяемости и сопровождае- мости	22
2.7 Вывод по разделу проектирования	23
3 Реализация базы знаний и средств её использования	24
3.1 Выбор средств реализации	24
3.2 Реализация структуры и наполнения базы знаний	24
3.3 Реализация механизмов доступа и использования базы знаний	24
3.4 Демонстрация работы базы знаний	24
3.5 Методика тестирования	24
3.6 Тестовый набор и классификация тестов	24
3.7 Оформление и результаты тестирования	24
3.8 Анализ качества базы знаний	24
3.9 Вывод по разделу реализации	24
Заключение	25
Список использованных источников	25

ПЕРЕЧЕНЬ УСЛОВНЫХ ОБОЗНАЧЕНИЙ

<i>БЗ</i>	– база знаний
<i>ВК</i>	– вики-система
<i>ЭС</i>	– экспертная система
<i>СУЗ</i>	– система управления знаниями
<i>СП</i>	– сообщество практики
<i>AI</i>	– искусственный интеллект
<i>IT</i>	– информационные технологии
<i>KPI</i>	– ключевые показатели эффективности
<i>KM</i>	– управление знаниями
<i>ROI</i>	– возврат инвестиций

ВВЕДЕНИЕ

Современное образование характеризуется активным внедрением цифровых технологий, направленных на повышение эффективности учебного процесса и сокращение времени на выполнение рутинных задач. Одной из таких задач является проверка студенческих работ, которая требует от преподавателя значительных временных затрат. Необходимо анализировать содержание документов, проверять их структуру, соответствие требованиям оформления и фиксировать найденные нарушения. В связи с этим актуальной является разработка интеллектуальных систем, способных автоматизировать отдельные этапы проверки учебных материалов.

Важной частью такой системы является база знаний, в которой хранятся правила, параметры и ограничения, используемые при анализе студенческих работ. Наличие базы знаний позволяет формализовать требования к оформлению документов, обеспечить единообразие проверки и упростить последующее расширение системы. Разработка базы знаний особенно важна в задачах, связанных с классификацией документов, диагностикой нарушений, выбором правил проверки и объяснением полученных результатов.

Целью данного курсового проекта является разработка базы знаний интеллектуальной системы автоматизации проверки студенческих работ.

Для достижения поставленной цели необходимо решить следующие задачи:

- выполнить анализ предметной области и определить основные задачи, решаемые системой;
- выявить требования к базе знаний;
- определить виды знаний и выбрать способ их представления;
- спроектировать структуру базы знаний;
- реализовать базу знаний и продемонстрировать её использование;
- провести тестирование и оценить результаты работы.

Объектом исследования является интеллектуальная система автоматизации проверки студенческих работ. Предметом исследования является база знаний данной системы, включающая правила проверки, способы представления знаний, структуру хранения и особенности использования при анализе документов.

В рамках курсового проекта рассматривается разработка базы знаний, предназначенной для работы с электронными документами в форматах DOCX и PDF. Система должна поддерживать задачи извлечения текста, применения правил проверки, выявления нарушений и формирования результатов анализа. При этом за рамками проекта остаются сложные механизмы интеллектуального вывода, полнофункциональные сетевые сервисы и расширенные средства интеграции с внешними информационными системами.

1 АНАЛИЗ ПРЕДМЕТНОЙ ОБЛАСТИ И ТРЕБОВАНИЙ К БАЗЕ ЗНАНИЙ

1.1 Характеристика предметной области

Предметной областью разрабатываемой системы является автоматизация проверки студенческих работ, представленных в электронном виде. К таким работам относятся лабораторные работы, курсовые работы, отчёты и другие учебные документы. Основная цель системы состоит в упрощении процесса проверки и сокращении времени, затрачиваемого преподавателем на анализ работ.

Основными объектами предметной области являются студенческая работа, файл документа, извлечённый текст, правила проверки и результаты анализа. Документ загружается в систему в формате DOCX или PDF, после чего из него извлекается текстовое содержимое. Далее этот текст анализируется по заданным правилам, связанным с оформлением и структурой работы.

К основным задачам предметной области относятся загрузка документов, извлечение текста, применение правил проверки и отображение результатов анализа. Ожидаемым результатом работы системы является выявление нарушений и представление преподавателю удобной информации о состоянии проверяемой работы.

Особенностями предметной области являются необходимость работы с документами различной структуры, требование к точности извлечения текста, а также использование методических указаний и правил оформления в качестве источников знаний ?. Кроме того, система должна обеспечивать приемлемое время обработки и наглядное представление результатов проверки ?.

1.2 Типы задач и сценарии использования

База знаний разрабатываемой системы предназначена для решения задач, связанных с автоматизированной проверкой студенческих работ. В рамках проекта она используется для хранения и применения правил, необходимых при анализе загруженных документов.

К основным типам задач, решаемых с использованием базы знаний, относятся классификация, диагностика, выбор и объяснение результатов проверки ?.

Задача классификации заключается в определении типа проверяемого документа и выборе соответствующего набора правил. Например, в зависимости от вида работы система может использовать разные требования к структуре, объёму и оформлению документа.

Задача диагностики связана с выявлением нарушений в оформлении и структуре студенческой работы. На основе правил, хранящихся в базе знаний, система определяет наличие отклонений от установленных требований, таких как отсутствие обязательных разделов, неправильное оформление заголовков, несоответствие параметров текста или другие ошибки.

Задача выбора состоит в определении правил и параметров, которые должны быть применены к конкретному документу. Выбор зависит от типа работы, заданных требований преподавателя или кафедры, а также особенностей конкретного сценария проверки.

Задача объяснения заключается в формировании понятного для пользователя результата проверки. Система должна не только выявлять нарушения, но и указывать, какое именно правило было нарушено, а также представлять описание ошибки в удобной форме.

С использованием базы знаний могут быть реализованы следующие сценарии:

а) Проверка загруженной работы. Пользователь загружает документ в формате DOCX или PDF, после чего система извлекает текст и передаёт данные модулю анализа. Далее выполняется обращение к базе знаний, из которой выбираются правила, соответствующие данному типу работы. В результате пользователь получает информацию о найденных нарушениях и итогах проверки.

б) Использование наборов требований. Пользователь или администратор задаёт параметры проверки, например, выбирает кафедру, дисциплину или тип работы. После этого система обращается к базе знаний и применяет только тот набор правил, который соответствует заданным условиям. Результатом является более точная и адаптированная проверка документа.

в) Формирование итогового отчёта. После завершения анализа система использует сведения из базы знаний для интерпретации выявленных нарушений и подготовки текстовых сообщений. В результате формируется отчёт, содержащий перечень ошибок и замечаний, представленный в понятной для преподавателя форме.

г) Обновление базы знаний. Администратор или разработчик может добавлять новые правила, изменять существующие требования и уточнять параметры проверки. После обновления базы знаний система получает возможность использовать новые данные без изменения основной логики работы приложения.

База знаний в разрабатываемой системе используется для решения задач классификации, диагностики, выбора и объяснения. Она обеспечивает применение формализованных правил при анализе студенческих работ и позволяет формировать результаты проверки в удобной и понятной для пользователя форме.

1.3 Анализ существующих решений и баз знаний

В области автоматизации проверки студенческих работ существует ряд программных решений, предназначенных для анализа текстовых документов, проверки оригинальности, применения критериев оценивания и формирования отчетов. Такие системы позволяют сократить время проверки, повысить единообразие оценки и упростить работу преподавателя.

С точки зрения решаемых задач можно выделить несколько типовых подходов к автоматизации проверки студенческих работ, различающихся назначением системы, способом хранения знаний и формой представления результатов.

Таблица 1.1 – Анализ структур баз знаний существующих решений

Система	Назначение	Преимущества	Ограничения	Применение
Turnitin	Проверка текстов на заимствования и формирование отчетов о совпадениях	Высокая эффективность поиска совпадений, удобные отчеты, широкое применение в образовании	Основной акцент сделан на плагиат, а не на оформление и структуру документа	Высокая для анализа оригинальности
Gradescope	Автоматизация проверки заданий и применение критериев оценивания	Удобство использования рубрик, сокращение времени проверки, поддержка разных типов заданий	Ориентирован в первую очередь на оценивание, а не на проверку оформления документа	Высокая для формализованной оценки
PlagScan	Проверка документов на текстовые совпадения и работа с отчетами	Простота использования, интеграция с образовательными платформами	Ограниченная функциональность в части анализа структуры и форматирования	Средняя для проверки заимствований
Локальные системы проверки документов	Контроль структуры, оформления и параметров текстовых файлов	Возможность адаптации под требования конкретной организации	Ограниченность набора правил и отсутствие универсального подхода	Высокая для прикладных локальных решений

Из приведённого анализа можно сделать вывод, что существующие решения, как правило, ориентированы либо на проверку заимствований, либо на поддержку процесса оценивания. При этом задача комплексной автоматической проверки студенческих работ, включающая анализ структуры документа, параметров оформления и формирование понятного отчёта, реализуется не во всех системах в полном объёме.

1.4 Характеристика аналогичных решений

Существующие системы автоматизированной проверки студенческих работ различаются не только по функциональному назначению, но и по способу организации базы знаний, лежащей в их основе.

Система Turnitin предназначена для выявления текстовых заимствований в документах. Принцип её работы основан на сравнении содержания проверяемого документа с внутренними и внешними источниками. База знаний данной системы имеет преимущественно документный характер и представляет собой крупное хранилище текстовых документов, их представлений, а также метаданных и результатов анализа совпадений. Такая структура эффективна для поиска заимствований, однако менее удобна для хранения формализованных правил оформления студенческих работ ?.

Система Gradescope применяется для автоматизации оценивания студенческих работ. В её основе лежит более структурированная база знаний, включающая критерии оценивания, рубрики, параметры заданий и шаблоны проверки. Такая форма представления знаний обеспечивает удобство сопровождения и изменения критериев, а также единообразие оценивания. Однако основное назначение системы связано с процессом оценивания, а не с детальной проверкой структуры и оформления документа ?.

Система PlagScan, аналогично Turnitin, ориентирована на проверку документов на наличие текстовых совпадений. Её база знаний также строится вокруг текстовых источников, результатов сравнения и отчётов о совпадениях. Данный подход обеспечивает высокую эффективность при анализе оригинальности текста, но характеризуется слабой ориентированностью на проверку структуры и форматирования документов ?.

Кроме того, существуют локальные системы проверки документов, разрабатываемые для нужд конкретной организации или учебной задачи. Для таких решений характерно использование таблиц параметров, наборов правил и шаблонов сообщений о нарушениях. В отличие от рассмотренных систем, их базы знаний ориентированы на хранение формализованных требований к оформлению, ограничений по структуре документа и правил проверки. Это делает их наиболее близкими к задачам разрабатываемой системы ?.

Рассмотрим сильные и слабые стороны существующих подходов. Документно-ориентированные базы знаний обладают высокой полнотой в части хранения текстовых материалов и хорошо подходят для поиска совпадений. Их сильной стороной является масштабируемость и удобство анализа текстов, а слабой — недостаточная формализация правил оформления.

Структурированные базы знаний, основанные на рубриках, правилах и параметрах проверки, удобны для сопровождения, расширения и применения в автоматическом анализе. Их преимуществом является воз-

возможность явного описания критериев, однако они требуют предварительной формализации предметной области ?.

Комбинированные подходы, сочетающие хранение текстовых данных, параметров проверки и формализованных правил, являются наиболее подходящими для систем автоматизации проверки студенческих работ. Они позволяют учитывать как содержимое документа, так и его структурные и оформительские характеристики ?.

Проведённый анализ показывает, что для разрабатываемой системы наиболее целесообразно использовать комбинированный подход к построению базы знаний. В такой базе должны храниться правила оформления студенческих работ, параметры проверки, ограничения на структуру документа, сведения о типовых нарушениях и шаблоны формирования отчётов. Это позволит реализовать автоматическую проверку документов не только с точки зрения текстового содержания, но и с точки зрения соответствия установленным требованиям оформления.

1.5 Анализ требований к базе знаний

База знаний системы должна обеспечивать хранение, структурирование и использование правил, необходимых для автоматизированной проверки студенческих работ на соответствие требованиям оформления и критериям анализа текстовых заимствований. Она должна поддерживать применение формализованных правил к загружаемым документам и обеспечивать формирование результатов проверки.

База знаний должна обеспечивать:

- хранение правил оформления студенческих работ, включая требования к структуре документа, форматированию текста, оформлению заголовков, списков, таблиц, рисунков и списка литературы ?;
- хранение критериев проверки текстовых заимствований и параметров оценки оригинальности работы;
- представление правил в формализованном виде, пригодном для автоматической обработки системой ?;
- использование различных наборов правил в зависимости от типа работы (лабораторная работа, курсовая работа, отчёт по практике и др.);
- поддержку настройки правил проверки под требования конкретной кафедры, дисциплины или преподавателя;
- предоставление описания нарушений и соответствующих рекомендаций по их исправлению;
- формирование данных для построения итогового отчёта о результатах проверки;
- обновление и редактирование набора правил без необходимости изменения программного кода системы;

- хранение версий правил и возможность использования актуального набора требований при выполнении проверки;
- поддержку взаимодействия с модулями анализа документа, извлечения текста и визуализации результатов проверки.

К базе знаний предъявляются требования, обеспечивающие корректность, согласованность и эффективность функционирования системы автоматизированной проверки студенческих работ.

База знаний должна удовлетворять следующим требованиям:

- полнота представления знаний: база знаний должна содержать все основные правила и критерии, необходимые для проверки оформления и анализа содержания студенческих работ;
- непротиворечивость: содержащиеся в базе знаний правила не должны конфликтовать друг с другом в пределах одной предметной области или одного типа документа;
- актуальность: должна быть обеспечена возможность своевременного обновления требований в соответствии с действующими методическими указаниями;
- расширяемость: структура базы знаний должна позволять добавление новых правил, категорий требований и типов документов без изменения общей архитектуры системы;
- сопровождаемость: база знаний должна быть удобна для редактирования, проверки и сопровождения со стороны администратора или эксперта предметной области;
- производительность: обращение к базе знаний и применение правил в ходе проверки должны выполняться за приемлемое время;
- настраиваемость: база знаний должна поддерживать адаптацию под различные учебные подразделения и варианты методических требований;
- надёжность: база знаний должна обеспечивать сохранность правил и устойчивость к ошибкам при обновлении и использовании данных;
- понятность интерпретации: правила и результаты их применения должны быть представлены в форме, удобной для объяснения пользователю.

1.6 Требования к видам знаний и формализму

База знаний должна содержать различные виды знаний, необходимые для выполнения автоматической проверки студенческих работ и интерпретации её результатов.

В системе должны использоваться следующие виды знаний:

- декларативные знания: сведения о требованиях к оформлению документов, допустимых параметрах форматирования, обязательных структурных элементах работы и критериях оценки оригинальности текста;
- структурные знания: описание состава документа, взаимосвязей

между его разделами и классификации типов студенческих работ;

- процедурные знания: правила применения критериев проверки, последовательность анализа документа и логика формирования замечаний;
- знания об ограничениях: допустимые диапазоны параметров оформления, обязательные и запрещённые элементы, условия применимости конкретных правил;
- интерпретационные знания: шаблоны пояснений, используемые при формировании сообщений об обнаруженных нарушениях.

Для представления и обработки знаний целесообразно использовать следующие формализмы:

- структурированные записи о правилах проверки;
- таблицы параметров и ограничений для различных типов документов;
- продукционные правила вида «условие – действие»;
- метаданные, определяющие область применимости конкретного правила;
- шаблоны текстовых сообщений для формирования итогового отчёта о результатах проверки.

Используемые формализмы должны обеспечивать возможность формального описания требований к студенческим работам, их автоматического применения при анализе документов, а также удобство расширения и сопровождения базы знаний в процессе эксплуатации системы.

1.7 Вывод по разделу анализа

По результатам анализа можно сделать следующие выводы:

- предметная область связана с автоматизацией проверки студенческих работ в электронном виде;
- база знаний должна использоваться для хранения правил оформления, параметров проверки и условий формирования результатов анализа;
- основными задачами системы являются классификация документов, выявление нарушений и представление результатов проверки;
- анализ аналогов показал необходимость создания решения, поддерживающего не только проверку заимствований, но и контроль структуры и оформления работ;
- при проектировании базы знаний необходимо учитывать требования полноты, актуальности, непротиворечивости, расширяемости и удобства сопровождения;
- в качестве основы для проектирования будут использоваться структурированные правила и параметры, применяемые при автоматическом анализе загружаемых документов.

2 ПРОЕКТИРОВАНИЕ БАЗЫ ЗНАНИЙ ИНТЕЛЛЕКТУАЛЬНОЙ СИСТЕМЫ

2.1 Общая архитектура интеллектуальной системы и место модуля базы знаний на основе Neo4j

Интеллектуальная система автоматизации проверки студенческих работ строится по модульному принципу и включает подсистемы загрузки документа, предварительного анализа, определения типа документа, определения семестра, проверки требований, формирования отчёта и хранения результатов. В данной архитектуре особое место занимает модуль базы знаний, реализованный на основе графовой базы данных Neo4j.

Назначение данного модуля состоит в хранении формализованных сведений о типах документов, семестрах, требованиях, проверках, нарушениях и отчётах, а также в обеспечении быстрого доступа к этим сведениям со стороны интеллектуальных подсистем системы. В отличие от файлового или табличного хранения, графовая база данных позволяет явно задавать связи между сущностями предметной области и использовать их при анализе документа.

В состав основных функций модуля базы знаний входят:

- хранение графовой модели предметной области;
- хранение требований к различным типам студенческих работ;
- хранение признаков, используемых для определения типа документа и семестра;
- предоставление данных модулю анализа для выполнения проверки;
- сохранение результатов анализа, найденных нарушений и итоговых отчётов;
- обеспечение возможности расширения набора правил без изменения общей архитектуры системы.

Работа модуля базы знаний начинается после загрузки и предварительной обработки документа. Подсистема анализа получает извлечённые из файла текстовые и структурные признаки, после чего обращается к Neo4j для выбора возможных типов документа, семестров и применимых требований. Затем модуль проверки использует найденные в графе правила для сопоставления их с характеристиками документа. При обнаружении несоответствий в графовой базе создаются записи о нарушениях, связанных как с конкретным документом, так и с нарушенными требованиями. На завершающем этапе в граф сохраняются сведения о выполненной проверке и отчёте.

С архитектурной точки зрения модуль базы знаний выполняет роль центрального слоя знаний, через который проходят основные интеллектуальные операции системы. Он не является пользовательским модулем и не

взаимодействует напрямую с пользователем, однако именно он обеспечивает внутренние подсистемы структурированными знаниями о предметной области. Благодаря этому анализ документа выполняется не по жёстко зашитым в коде правилам, а на основе данных, хранящихся в отдельной расширяемой базе знаний.

Архитектурная схема взаимодействия модуля базы знаний с остальными подсистемами приведена на рисунке 2.1.




Рисунок 2.1 – Архитектурная схема взаимодействия модуля базы знаний с остальными подсистемами

Таким образом, модуль базы знаний на основе Neo4j является ядром хранения и использования формализованных знаний в системе автоматизации проверки студенческих работ. Он обеспечивает связность между типами документов, семестрами, требованиями и результатами анализа, что делает его ключевым элементом общей архитектуры интеллектуальной системы.

2.2 Выбор графового формализма и логической основы

При проектировании базы знаний выбран графовый формализм представления знаний, реализуемый в Neo4j в виде модели property graph. В рамках данной модели предметная область описывается через узлы, связи

и свойства. Такой подход является особенно удобным для рассматриваемой системы, поскольку в ней присутствует большое количество взаимосвязанных сущностей: документ связан с типом документа и семестром, тип документа связан с набором требований, нарушение связано с конкретным требованием, а отчёт связан с выполненной проверкой.

Выбор Neo4j обусловлен следующими причинами:

- графовая модель естественным образом описывает структуру предметной области;
- связи между сущностями являются полноправными элементами модели и могут использоваться при выполнении запросов;
- добавление новых типов документов, семестров и требований не требует радикального изменения структуры хранения;
- язык запросов Cypher позволяет наглядно описывать чтение и запись связанных данных;
- графовая база знаний хорошо подходит для хранения как правил, так и результатов их применения.

В рамках выбранного формализма используются следующие основные синтаксические и семантические элементы:

- *узел* — сущность предметной области, например документ, тип документа, семестр, требование, проверка, нарушение или отчёт;
- *связь* — направленное отношение между сущностями, например «документ относится к типу», «требование применяется к семестру», «нарушение связано с требованием»;
- *свойство* — атрибут узла или связи, например идентификатор, название, уровень критичности, дата проверки или статус;
- *шаблон правила* — структурированное описание требования, связанное с областью его применимости;
- *факт проверки* — результат выполнения проверки конкретного документа, включая список найденных нарушений и итоговый статус.

Семантика графовой модели заключается в том, что знания представляются не как изолированные записи, а как сеть взаимосвязанных объектов. Например, требование не существует само по себе, а связано с определённым типом документа и, при необходимости, с конкретным семестром. Нарушение также не является самостоятельной сущностью вне контекста: оно связано с проверкой, документом и тем требованием, которое было нарушено.

Для обеспечения корректности логической модели вводятся следующие правила:

- каждый документ должен иметь уникальный идентификатор;
- каждое требование должно иметь уникальный код или идентификатор;
- каждое нарушение должно быть связано с конкретной проверкой и

конкретным требованием;

- каждый отчёт должен относиться к одной выполненной проверке;
- связи между типами документов, семестрами и требованиями должны быть определены явно, без неоднозначности;
- результаты проверки должны сохраняться отдельно от нормативных знаний, но быть логически связаны с ними.

Таким образом, графовый формализм и модель property graph являются логически обоснованным выбором для проектирования базы знаний системы. Они позволяют формально описать как постоянные знания о предметной области, так и динамические результаты анализа загружаемых документов.

2.3 Концептуальная графовая модель данных

Концептуальная модель базы знаний ориентирована на описание сущностей, необходимых для хранения правил проверки и результатов анализа документа. В качестве основных сущностей в графовой модели используются «Документ», «ТипДокумента», «Семестр», «Требование», «Проверка», «Нарушение» и «Отчёт».

Центральное место в модели занимает сущность «Документ», поскольку именно для неё выполняются операции определения типа, определения семестра, проверки соответствия требованиям и формирования отчёта. Сущность «ТипДокумента» используется для классификации учебных работ, а сущность «Семестр» — для выбора подмножества требований, актуальных для конкретного этапа обучения.

Сущность «Требование» описывает отдельное правило проверки. Для каждого требования могут задаваться категория, уровень критичности, описание, способ интерпретации нарушения и область применимости. Сущность «Проверка» фиксирует факт выполнения анализа конкретного документа. Сущность «Нарушение» хранит сведения о несоответствии документа требованию, а сущность «Отчёт» представляет итоговую форму результата проверки.

На рисунке 2.2 представлена концептуальная графовая модель данных модуля базы знаний.




Рисунок 2.2 – Концептуальная графовая модель данных модуля базы знаний

В разработанной модели используются следующие основные связи:

- документ относится к определённому типу документа;
- документ соотносится с определённым семестром;
- требование применяется к типу документа;
- требование применяется к семестру;
- проверка выполняется для документа;
- проверка использует требования;

- проверка выявляет нарушения;
- нарушение нарушает конкретное требование;
- отчёт формируется по результатам проверки.

Такое представление данных позволяет хранить в одном графе как нормативные знания, так и результаты анализа. Нормативная часть графа включает типы документов, семестры и требования. Оперативная часть включает документы, проверки, нарушения и отчёты. За счёт этого достигается удобное разделение статических и динамических знаний без потери связности между ними.

Таким образом, концептуальная графовая модель данных описывает основу структуры базы знаний и задаёт формальное представление сущностей, используемых при интеллектуальной проверке студенческих работ.

2.4 Логическая и физическая структура модуля базы знаний

Логическая структура

Логическая структура модуля базы знаний строится как совокупность нескольких взаимосвязанных компонентов, обеспечивающих хранение, загрузку, чтение и запись знаний в графовую базу данных Neo4j.

В логической структуре модуля базы знаний выделяются следующие основные компоненты:

- *слой схемы графа*, определяющий набор меток узлов, типов связей, ограничений и индексов;
- *слой наполнения базы знаний*, предназначенный для первоначальной загрузки типов документов, семестров и требований;
- *слой запросов чтения*, обеспечивающий получение правил и связанных данных для модулей анализа;
- *слой запросов записи*, обеспечивающий сохранение фактов проверки, нарушений и отчётов;
- *интеграционный слой*, связывающий Neo4j с модулями анализа, определения типа документа, определения семестра и формирования отчёта.

Через слой запросов чтения система получает сведения о том, какие требования относятся к конкретному типу документа и семестру. Через слой запросов записи в граф заносятся результаты анализа конкретного документа. Интеграционный слой обеспечивает согласование форматов данных и преобразование результатов анализа в операции записи в Neo4j.

Более детально внутренняя организация модуля базы знаний представлена на диаграмме компонентов, приведённой на рисунке 2.3.




Рисунок 2.3 – Диаграмма компонентов модуля базы знаний на основе Neo4j

Физическая структура и форматы хранения

На физическом уровне база знаний реализуется как отдельная подсистема проекта, использующая Neo4j для хранения графовых данных и Cypher для выполнения операций чтения и записи.

Физическая структура модуля может включать следующие каталоги и файлы:

- каталог `neo4j/schema/`, содержащий файлы ограничений и индексов;
- каталог `neo4j/data/`, содержащий скрипты первоначального наполнения базы знаний;
- каталог `neo4j/queries/`, содержащий шаблоны запросов чтения и записи;
- каталог `neo4j/import/`, содержащий вспомогательные данные для загрузки;
- модуль доступа к БД, реализующий подключение к Neo4j и вызов запросов Cypher.

В работе модуля базы знаний используются следующие основные форматы данных:

- графовые данные Neo4j — для хранения узлов, связей и их свойств;
- Cypher — как основной язык запросов к графовой базе данных;
- JSON — как формат обмена данными между Neo4j и остальными подсистемами системы;
- PDF и DOCX — как исходные документы, результаты анализа которых отражаются в графе в виде сущностей и связей.

Для минимизации дублирования данных в графе нормативные знания и результаты проверки разделяются по типам сущностей. Типы документов, семестры и требования хранятся как относительно устойчивые объекты базы знаний, а документы, проверки, нарушения и отчёты — как операционные данные, создаваемые в процессе работы системы.

Таким образом, логическая и физическая структура модуля базы знаний обеспечивает удобное хранение связанной информации, прозрачное разделение обязанностей между компонентами и возможность интеграции Neo4j с остальными частями интеллектуальной системы.

2.5 Моделирование видов знаний и запросов в Neo4j

Декларативные знания

В рамках модуля базы знаний декларативные знания представлены в виде структурированных сведений о предметной области, необходимых для автоматической проверки студенческих работ. К ним относятся:

- сведения о типах учебных документов;
- сведения о семестрах и признаках их определения;
- сведения о требованиях к структуре и оформлению документа;
- сведения о категориях нарушений и уровнях их критичности;
- сведения о шаблонах интерпретации результатов проверки.

Примерами декларативных знаний, хранимых в графе, являются следующие утверждения:

- пояснительная записка является типом документа;
- требование наличия введения применяется к выбранному типу документа;
- определённое требование относится к конкретному семестру;
- нарушение оформления связано с конкретным требованием;
- отчёт формируется на основе результатов проверки.

Процедурные знания и операции

Процедурная составляющая модуля базы знаний связана не с полным выполнением интеллектуального вывода, а с обеспечением операций доступа к знаниям и сохранения результатов анализа. В рамках этой составляющей реализуются следующие основные действия:

- получение набора требований по типу документа и семестру;
- получение сведений о типах документов и их признаках;
- запись информации о выполненной проверке;
- запись найденных нарушений;
- запись и чтение итогового отчёта.

Ключевые правила работы модуля базы знаний можно сформулировать следующим образом:

- если тип документа и семестр определены, то из графа выбирается только релевантный набор требований;
- если требование нарушено, то создаётся сущность нарушения и связь с соответствующей проверкой;
- если проверка завершена, то в графе фиксируется итоговый статус проверки;
- если отчёт сформирован, то он связывается с выполненной проверкой и исходным документом;
- если в базу знаний добавляется новый тип документа или новый набор требований, то существующая структура графа не должна нарушаться.

Временной порядок обращения к Neo4j при анализе документа показан на диаграмме последовательности, приведённой на рисунке 2.4.




Рисунок 2.4 – Диаграмма последовательности обращения к Neo4j при анализе документа

Диаграмма отражает следующий порядок работы. Сначала модуль анализа запрашивает из графовой базы знаний правила, соответствующие

определённому типу документа и семестру. Затем после выполнения проверки система передаёт в модуль доступа к Neo4j сведения о результатах анализа, которые сохраняются в виде сущностей проверки, нарушений и отчёта. После этого модуль формирования отчёта может получить из графа полные данные о найденных нарушениях и итоговом результате.

Таким образом, в Neo4j декларативные знания определяют структуру и содержание правил проверки, а процедурные операции обеспечивают использование этих знаний в процессе анализа студенческих работ.

2.6 Обеспечение согласованности, расширяемости и сопровождаемости

Согласованность базы знаний обеспечивается за счёт единого подхода к моделированию узлов и связей, применения ограничений целостности и разделения нормативных и операционных данных. Для каждой ключевой сущности в графе задаётся фиксированный набор обязательных атрибутов, позволяющий однозначно идентифицировать объект и использовать его в запросах.

Контроль согласованности обеспечивается следующими механизмами:

- введением уникальных ограничений на идентификаторы документов, требований, проверок, нарушений и отчётов;
- явным заданием допустимых типов связей между узлами;
- использованием индексов для ключевых полей поиска;
- отделением правил проверки от результатов их применения;
- проверкой корректности загружаемых данных при наполнении графа;
- использованием согласованных шаблонов запросов Cypher.

Расширяемость базы знаний обеспечивается тем, что графовая модель допускает добавление новых сущностей и связей без перестройки уже существующей структуры. Например, для включения нового типа документа достаточно добавить соответствующий узел и связать его с нужными требованиями. Аналогично можно расширить набор семестров, категорий нарушений или шаблонов отчётов.

Сопровождаемость модуля базы знаний обеспечивается разделением его структуры на независимые уровни: схема графа, начальное наполнение, запросы чтения, запросы записи и интеграционный слой. Благодаря этому изменение правил проверки не требует изменения кода интерфейса, а изменение набора сохраняемых результатов не требует переработки нормативной части базы знаний.

Эволюция базы знаний должна выполняться по следующим правилам:

- новые требования добавляются без нарушения существующих связей;

- изменения в структуре графа должны сопровождаться обновлением ограничений и шаблонов запросов;
- новые типы документов и семестры должны включаться в базу знаний через явное связывание с требованиями;
- изменения базы знаний должны проверяться на типовых сценариях анализа документа.

Таким образом, принятая структура модуля базы знаний обеспечивает непротиворечивость представления знаний, удобство расширения и сопровождения, а также устойчивость к развитию функциональности системы.

2.7 Вывод по разделу проектирования

В ходе проектирования модуля базы знаний интеллектуальной системы автоматизации проверки студенческих работ было определено его место в общей архитектуре системы, выбрана графовая модель представления знаний и обосновано использование Neo4j в качестве средства хранения взаимосвязанных сущностей предметной области.

Построенная концептуальная модель включает основные объекты, необходимые для проверки документов: документ, тип документа, семестр, требование, проверка, нарушение и отчёт. Разработанная логическая и физическая структура модуля базы знаний обеспечивает хранение нормативных сведений, поддержку операций чтения и записи, а также интеграцию с модулями анализа и формирования отчёта.

Использование Neo4j позволяет явно представить связи между сущностями, упростить расширение набора правил и обеспечить сохранение результатов анализа в единой графовой структуре. Принятые проектные решения обеспечивают согласованность, расширяемость и сопровождаемость базы знаний в составе интеллектуальной системы.

3 РЕАЛИЗАЦИЯ БАЗЫ ЗНАНИЙ И СРЕДСТВ ЕЁ ИСПОЛЬЗОВАНИЯ

3.1 Выбор средств реализации

Языки, форматы, библиотеки и инструменты
Обоснование выбора средств

3.2 Реализация структуры и наполнения базы знаний

3.3 Реализация механизмов доступа и использования базы знаний

3.4 Демонстрация работы базы знаний

3.5 Методика тестирования

3.6 Тестовый набор и классификация тестов

3.7 Оформление и результаты тестирования

3.8 Анализ качества базы знаний

3.9 Вывод по разделу реализации

ЗАКЛЮЧЕНИЕ